

# Visualisierung – Wann welche Darstellung?

## Exploration anhand des Titanic-Datensatzes

**Leitfrage:** Welche Visualisierung ist für welche Fragestellung geeignet – und warum?

Datensatz Quelle: <https://github.com/mwaskom/seaborn-data/blob/master/titanic.csv>

Bereitgestellt von: <https://seaborn.pydata.org/>

Jupyter Notebook von: Devin Rohrer

```
In [1]: import seaborn as sns
import matplotlib.pyplot as plt

# Originaler titanic datensatz
df = sns.load_dataset('titanic')

# Styling
sns.set_theme(style='whitegrid', palette='muted')
plt.rcParams['figure.dpi'] = 110

print(f'Datensatz: {df.shape[0]} Passagiere, {df.shape[1]} Merkmale')
print(f'Überlebensrate gesamt: {df["survived"].mean():.1%}')

# Die ersten 5 Zeilen ausgeben
df.head()
```

Datensatz: 891 Passagiere, 15 Merkmale

Überlebensrate gesamt: 38.4%

```
Out[1]:   survived  pclass    sex   age  sibsp  parch     fare embarked  class  who  adult
0          0       3  male  22.0      1      0    7.2500        S  Third   man
1          1       1 female  38.0      1      0   71.2833        C  First  woman
2          1       3 female  26.0      0      0    7.9250        S  Third  woman
3          1       1 female  35.0      1      0   53.1000        S  First  woman
4          0       3  male  35.0      0      0    8.0500        S  Third   man
```

# 1. Visualisierung: Histogramm

## Wann ein Histogramm?

Immer dann, wenn man eine **einzelne numerische Variable** hat und verstehen will, wie die Werte verteilt sind – wo die Masse liegt, ob es Ausreißer gibt, ob die Verteilung symmetrisch oder schief ist.

Frage: Wie ist das Alter der Passagiere verteilt?

```
In [2]: fig, ax = plt.subplots(figsize=(9, 5))


# Histogramm erstellen:
ax.hist(df['age'], bins=30, color='steelblue', edgecolor='white', linewidth=0.

# Median berechnen und visualisieren:
median_age = df['age'].median()
ax.axvline(median_age, color='tomato', linestyle='--', linewidth=2,
           label=f'Median: {median_age:.0f} Jahre')

ax.set_title('Altersverteilung der Titanic-Passagiere', fontsize=15, fontweight='bold')
ax.set_xlabel('Alter', fontsize=12)
ax.set_ylabel('Anzahl Passagiere', fontsize=12)
ax.legend(fontsize=11)

sns.despine()
plt.tight_layout()
plt.show()

print(f"Median: {df['age'].median():.0f} Jahre | Mittelwert: {df['age'].mean():.0f} Jahre")
print(f"Jüngster: {df['age'].min():.0f} Jahre | Ältester: {df['age'].max():.0f} Jahre")
```



Median: 28 Jahre | Mittelwert: 29.7 Jahre  
Jüngster: 0 Jahre | Ältester: 80 Jahre

**Beobachtung:** Die meisten Passagiere waren zwischen 20 und 40 Jahre alt. Es gibt einen kleinen Peak bei Kindern und einige ältere Passagiere als Ausreißer.

**Wann kein Histogramm?** Wenn man Gruppen miteinander vergleichen möchte – dafür ist der Boxplot deutlich besser geeignet (s. Visualisierung 3).

---

## 2. Visualisierung: Balkendiagramm

### Wann ein Balkendiagramm?

Wenn man **kategorische Gruppen vergleicht** – z.B. Klassen, Geschlecht, Herkunft. Balken machen Unterschiede zwischen Kategorien direkt und präzise ablesbar.

Frage: Wie unterscheidet sich die Überlebensrate nach Reiseklasse und Geschlecht?

```
In [3]: survival = df.groupby(['pclass', 'sex'])['survived'].mean().reset_index()
survival['survived_pct'] = survival['survived'] * 100

fig, ax = plt.subplots(figsize=(9, 5))


colors_sex = {'male': 'steelblue', 'female': 'tomato'}
labels_sex = {'male': 'Männer', 'female': 'Frauen'}
x = [0, 1, 2]
width = 0.35

for i, (sex, grp) in enumerate(survival.groupby('sex')):
    offset = -width / 2 if i == 0 else width / 2
    bars = ax.bar([xi + offset for xi in x], grp['survived_pct'],
                  width=width, label=labels_sex[sex], color=colors_sex[sex], alpha=0.7)
    for bar in bars:
        h = bar.get_height()
        ax.text(bar.get_x() + bar.get_width() / 2, h + 1.2, f'{h:.0f}%', ha='center', va='bottom', fontsize=10.5)

ax.set_xticks(x)
ax.set_xticklabels(['1. Klasse', '2. Klasse', '3. Klasse'], fontsize=12)
ax.set_ylabel('Überlebensrate (%)', fontsize=12)
ax.set_ylim(0, 115)
ax.set_title('Überlebensrate nach Klasse und Geschlecht', fontsize=15, fontweight='bold')
ax.legend(fontsize=11)

sns.despine()
plt.tight_layout()
plt.show()
```

## Überlebensrate nach Klasse und Geschlecht



**Beobachtung:** Frauen überlebten in allen Klassen deutlich häufiger. Klassenunterschiede sind stark erkennbar. **Warum kein Tortendiagramm?** Tortendiagramme eignen sich nur für Anteile eines Ganzen mit wenigen Kategorien. Für Gruppenvergleiche sind Balken fast immer besser – Längen lassen sich viel präziser ablesen als Winkel.

---

## 3. Visualisierung: Boxplot

### Wann ein Boxplot?

Wenn man eine **numerische Variable über mehrere Gruppen hinweg vergleichen** möchte. Der Boxplot zeigt Median, Streuung (IQR) und Ausreißer auf einmal – ein Histogramm könnte das nur mit mehreren überlagerten Grafiken.

*Frage:* Unterscheidet sich das Alter zwischen Überlebenden und Nicht-Überlebenden?

```
In [4]: df_box = df.copy()
df_box['Überleben'] = df_box['survived'].map({0: 'Nicht überlebt', 1: 'Überlebt'})

fig, ax = plt.subplots(figsize=(8, 5))

sns.boxplot(
    data=df_box, x='Überleben', y='age',
    hue='Überleben', legend=False,
    palette={'Nicht überlebt': 'steelblue', 'Überlebt': 'tomato'},
    width=0.4, linewidth=1.5, ax=ax
)

ax.set_title('Altersverteilung nach Überlebensstatus', fontsize=15, fontweight='bold')
ax.set_xlabel('', fontsize=12)
ax.set_ylabel('Alter', fontsize=12)

ax.text(1.38, 58,
        'Strich = Median\nKasten = 25–75% (IQR)\nPunkte = Ausreißer',
```


```

    fontsize=9, color='#444',
    bbox=dict(boxstyle='round', pad=0.5, facecolor='lightyellow',
              edgecolor='gray', alpha=0.85))

sns.despine()
plt.tight_layout()
plt.show()

for gruppe, data in df_box.groupby('Überleben'):
    print(f'{gruppe}: Median = {data["age"].median():.1f} | IQR = {data["age"]')

```



Nicht überlebt: Median = 28.0 | IQR = 21.0 – 39.0

Überlebt: Median = 28.0 | IQR = 19.0 – 36.0

**Beobachtung:** Der Median ist bei beiden Gruppen ähnlich. Kinder tauchen leicht häufiger unter den Überlebenden auf.

**Wann kein Boxplot?** Bei sehr kleinen Stichproben (< 20 Werte) – dann ist ein Strip- oder Swarmplot ehrlicher, weil er die einzelnen Datenpunkte zeigt.

## 4. Visualisierung: Scatterplot

### Wann ein Scatterplot?

Wenn man den **Zusammenhang zwischen zwei numerischen Variablen** untersucht.

Durch Farbe kann man gleichzeitig eine dritte (kategoriale) Variable einbinden – so werden drei Dimensionen in einer Grafik sichtbar.

*Frage:* Gibt es einen Zusammenhang zwischen Alter, Fahrpreis und Überleben?

```
In [5]: df_scatter = df.copy()
df_scatter['Überleben'] = df_scatter['survived'].map({0: 'Nicht überlebt', 1:

```

```

fig, ax = plt.subplots(figsize=(9, 5))


colors_map = {'Nicht überlebt': 'steelblue', 'Überlebt': 'tomato'}
for gruppe, grp in df_scatter.groupby('Überleben'):
    ax.scatter(grp['age'], grp['fare'], label=gruppe,
               alpha=0.45, s=35, color=colors_map[gruppe], edgecolors='none')

ax.set_title('Alter vs. Fahrpreis – eingefärbt nach Überleben', fontsize=15, fontweight='bold')
ax.set_xlabel('Alter', fontsize=12)
ax.set_ylabel('Fahrpreis (£)', fontsize=12)
ax.set_ylim(-5, 300)
ax.legend(fontsize=11)

ax.annotate('Höherer Ticketpreis \n-> mehr Überlebende',
            xy=(45, 210), xytext=(54, 255),
            fontsize=9, color='#555',
            arrowprops=dict(arrowstyle='->', color='#555'))

sns.despine()
plt.tight_layout()
plt.show()

```



**Beobachtung:** Passagiere mit teuren Tickets (oben) überlebten häufiger – erkennbar an der höheren Dichte roter Punkte. Bei günstigen Tickets dominieren blaue Punkte.

**Wann kein Scatterplot?** Bei kategorischen Variablen auf beiden Achsen – dann lieber eine Heatmap oder ein Balkendiagramm.

## Anhang – Visualisierung 5: Heatmap

### Korrelationsmatrix der numerischen Variablen

**Wann eine Heatmap?**

Wenn man schnell einen **Überblick über Zusammenhänge zwischen vielen Variablen**

bekommen möchte. Besonders nützlich am Anfang einer explorativen Analyse – als Orientierungshilfe, bevor man sich auf einzelne Variablen fokussiert.


```
In [6]: cols = ['survived', 'pclass', 'age', 'sibsp', 'parch', 'fare']
corr = df[cols].corr()

fig, ax = plt.subplots(figsize=(7, 5))

sns.heatmap(corr, annot=True, fmt='.2f', cmap='coolwarm', center=0,
            linewidths=0.5, square=True, ax=ax, annot_kws={'size': 10})

ax.set_title('Korrelationsmatrix – Titanic-Merkmale', fontsize=14, fontweight=
plt.tight_layout()
plt.show()

print("Stärkste Korrelationen mit 'survived':")
print(corr['survived'].drop('survived').sort_values(key=abs, ascending=False)).
```



Stärkste Korrelationen mit 'survived':

```
pclass   -0.338481
fare     0.257307
parch   0.081629
age     -0.077221
sibsp   -0.035322
```

**Beobachtung:** pclass hat die stärkste (negative) Korrelation mit survived . fare korreliert positiv. Das deckt sich mit dem, was wir im Scatterplot gesehen haben – die

Heatmap gibt den schnellen Überblick.

---

## Anhang – Visualisierung 6: Pairplot

Der folgende Python-Code im Anhang für Visualisierung Nr.6 wurde mithilfe von KI generiert und überprüft. Modell: Claude Sonnet 4.6.

### Alle numerischen Variablen auf einen Blick

#### Wann ein Pairplot?

Nur in der **frühen Explorationsphase**, wenn man noch gar nicht weiß, welche Variablen interessant sind. Für Berichte oder Präsentationen ist er meist zu unübersichtlich – er ist ein Werkzeug für den Analysten, nicht für das Publikum.


```
In [7]: """
Der folgende Code für das Pairplot wurde mit Hilfe von KI generiert.
Modell: Claude 4.6 Sonnet
"""

df_pair = df[['survived', 'age', 'fare', 'pclass']].copy()
df_pair['Überleben'] = df_pair['survived'].map({0: 'Nicht überlebt', 1: 'Überlebt'})

g = sns.pairplot(
    df_pair[['age', 'fare', 'pclass', 'Überleben']],
    hue='Überleben',
    palette={'Nicht überlebt': 'steelblue', 'Überlebt': 'tomato'},
    diag_kind='hist',
    plot_kws={'alpha': 0.4, 's': 18}
)

g.figure.suptitle('Pairplot – Überblick aller numerischen Variablen',
                  y=1.02, fontsize=13, fontweight='bold')
plt.tight_layout()
plt.show()
```

## Pairplot – Überblick aller numerischen Variablen



**Fazit:** Der Pairplot ist ein Tool für die eigene Analyse – nicht für die Kommunikation von Ergebnissen. Sobald man weiß, was interessant ist, greift man auf gezielte Einzelplots zurück.

---

## Zusammenfassung:

Ziel	Visualisierung
Verteilung <b>einer</b> numerischen Variable	<b>Histogramm</b>
Unterschiede nach <b>Kategorien</b>	<b>Balkendiagramm</b>
Verteilung zwischen <b>Gruppen</b> vergleichen	<b>Boxplot</b>
<b>Zusammenhänge</b> zwischen zwei Variablen erkennen	<b>Scatterplot</b>
<b>Korrelation</b> zweier Variablen	<b>Heatmap</b>
Interessante Variablen entdecken	<b>Pairplot</b> (nur Exploration)